

자기 증류에서의 추론 다양성

Reasoning diversity for Self-distillation

안성재^{1*}, 문상혁^{2*}, 정하규^{3*}
Sungjae Ahn^{1*}, Sanghyeok Moon^{2*}, Hakyu Jeong^{3*}

¹경희대학교 컴퓨터공학과, ²경희대학교 응용수학과, ³경희대학교 인공지능학과
*이 저자들은 공동 기여함.

요약

검증 가능한 보상을 활용한 강화학습(RLVR)은 대규모 언어 모델의 추론 성능을 향상시키는 대표적 사후학습 방법이지만, 기존 연구는 RLVR이 문제 커버리지를 확장하기보다 이미 샘플링 가능한 정답 경로의 확률을 높이는 데 그칠 수 있음을 지적한다. 본 연구는 이를 추론 전략 다양성의 관점에서 분석하고, 자기 증류 기반 강화학습 방법인 SDPO(Self-Distillation Policy Optimization)가 전략 붕괴를 완화할 수 있는지 검토한다. LiveCodeBench v6에서 Qwen3-8B를 기반으로 비교한 결과, SDPO는 Pass@16을 향상시켰지만 정답 전략 다양성을 크게 감소시켰고, Failure-only 학습은 상대적으로 높은 다양성을 보였다. 이를 바탕으로 성공 rollout에는 forward KL을, 실패 rollout에는 reverse KL을 적용하는 결과 기반 KL 라우팅 방법인 DSPO를 제안하였다. 실험 결과 DSPO는 SDPO의 극단적 단일 전략 수렴을 완화했으나, base 모델의 문제 커버리지를 확장하지는 못했다. 추가 분석은 손실 불균형과 KL 방향의 부적합성이 주요 원인임을 보였으며, 향후 분기별 손실 크기와 support 겹침 정도를 고려한 동적 라우팅이 필요함을 시사한다.

키워드: LLM, RLVR, Self-Distillation, Strategy Diversity, Result-Based KL Routing, Problem Coverage

1. Introduction

검증 가능한 보상을 활용한 강화학습(Reinforcement Learning with Verifiable Rewards, RLVR)은 정답 여부를 명확히 판별할 수 있는 과제에서 대규모 언어 모델(Large Language Model, LLM)의 추론 능력을 향상시키는 대표적인 사후학습(post-training) 기법이다. 특히 수학, 코딩과 같은 영역에서는 모델이 생성한 답변에 대해 명시적인 보상을 부여할 수 있기에 적극적으로 활용된다. 이러한 과제에서 RLVR은 추론 성능을 개선하는 효과적인 방법으로 주목받아 왔다. 그러나 최근 연구에 따르면 RLVR로 학습된 모델에서는 적은 수의 샘플로 정답에 도달하는 능력은 향상되는 반면, 풀 수 있는 문제의 범위 자체는 넓어지지 않을 수 있다[1]. 이는 RLVR이 새로운 추론 능력을 형성하기보다, 이미 샘플링 가능한 정답 경로의 확률을 높여 샘플링 효율성을 개선하는 방향으로 작동함을 시사한다.

이러한 한계는 자기 개선(self-improvement)의 관점에서 RL 학습에 중요한 문제다. 자기 개선이란 모델이 자신의 생성 결과를 바탕으로 기존 능력을 스스로 확장해 나가는 것을 의미하며, RL은 이러한 자기 개선을 가능하게 할 것으로 기대되어 왔다. 그러나 RLVR 학습이 모델의 문제 커버리지(풀 수

있는 문제의 범위)를 확장하지 못하고 오히려 기존에 샘플링 가능했던 일부 정답 경로마저 잃게 만든다면, 이는 단순한 성능 향상의 문제가 아니라 학습 과정에서 어떤 추론 경로가 보존되고 어떤 경로가 제거되는가의 문제로 이어진다. 실제 표준 RLVR로 학습된 모델은 동일한 문제에 대해 다양한 풀이 전략을 유지하기보다 특정 성공 전략에 고착되는 전략 붕괴(strategy collapse)를 보이는 것으로 보고되었다[2].

전략 다양성은 LLM의 추론 능력을 평가할 때 중요한 요소이다. 동일한 문제라도 여러 알고리즘 전략(예: 동적 계획법(dynamic programming), 탐욕 알고리즘(greedy algorithm))으로 해결될 수 있기 때문이다. 이때 하나의 풀이 전략에만 높은 확률을 집중하는 모델은 샘플링 효율성 측면에서는 우수해 보일 수 있으나, 다양한 문제 조건이나 분포 변화에 대응하는 유연성은 제한될 수 있다. 따라서 RLVR 기반 사후학습에서는 단순히 정답률을 높이는 것뿐만 아니라, 정답에 도달할 수 있는 다양한 추론 전략을 보존하는 것이 중요하다.

전략 다양성을 보존하려면, 실패한 rollout을 단순히 제거하거나 억제하는 대신 그 안에 담긴 잠재적 추론 신호를 학습에 활용할 필요가 있다. 그러나 LLM의 행동 공간(action space)은 매우 크기

때문에, 실패 경로 주변을 무작위로 탐색하는 방식은 현실적으로 어렵다. 따라서 실패한 rollout에 의미 있는 교정 신호를 제공하여, 모델이 기존에 도달하지 못한 정답 경로를 탐색할 수 있도록 하는 학습 구조가 필요하다.

본 연구는 이러한 문제의식에서 출발하여, 실패한 rollout에 대해서도 텍스트 피드백을 활용해 학습할 수 있는 자기 증류 기반 강화학습 방법인 SDPO(Self-Distillation Policy Optimization)[3]에 주목한다. 구체적으로 SDPO가 실패 rollout을 학습에 활용함에도 불구하고 전략 다양성을 보존하는지 분석하고, 실패 rollout이 전략 다양성 보존을 위한 유효한 학습 신호가 될 수 있는지 검토한다. 이를 위해 먼저 SDPO 학습 전후의 정답 전략 다양성 변화를 측정하고, 실패 rollout만을 활용한 학습 변형이 전략 다양성에 미치는 영향을 비교한다. 나아가 rollout의 성공 여부에 따라 서로 다른 KL 목적함수를 적용하는 결과 기반 라우팅(result-based routing) 방법을 제안하고, 성능과 다양성의 관점에서 그 효과와 한계를 분석한다.

2. Background & Related Work

2.1 Reinforcement Learning with Verifiable Rewards and Strategy Collapse

검증 가능한 보상을 활용한 강화학습(Reinforcement Learning with Verifiable Rewards, RLVR)은 수학, 코드 생성과 같이 정답 여부를 자동으로 판별할 수 있는 과제에서 대규모 언어 모델(Large Language Model, LLM)의 사후학습(post-training)에 널리 활용된다. 정책 π_{θ} 가 질문 x 에 대해 추론 궤적(rollout) $\tau \sim \pi_{\theta}(\cdot | x)$ 을 생성하면, 단위 테스트 통과 여부나 정답 일치 여부와 같은 검증 가능한 신호로부터 보상 $r(x, \tau) \in \{0, 1\}$ 이 주어진다. RLVR은 이 보상으로부터 각 궤적의 advantage를 산출하여, 양의 advantage를 갖는 궤적의 확률은 높이고 음의 advantage를 갖는 궤적의 확률은 낮추는 방향으로 정책을 갱신한다[7].

그러나 최근 연구에 따르면 이러한 학습은 모델의 추론 능력을 근본적으로 확장하기보다, 이미 모델이 샘플링할 수 있는 정답 경로의 확률을 높여 샘플링 효율을 개선하는 데 그칠 수 있다[1]. 예를 들어 k 개의 샘플 중 하나라도 정답이면 해결로 간주하는 pass@ k 로 평가할 때, RLVR 모델은 작은 (k)에서는 base 모델보다 높은 성능을 보일 수 있지만, k 가 커질수록 base 모델보다 낮은 문제 커버리지를 보일 수 있다[1].

이러한 커버리지 축소는 RLVR의 학습 신호 구조와 직접 연결된다. 모델은 현재 정책에서 이미 확률이 높은 소수의 성공 궤적을 우선적으로 강화하는 경향이 있어, 학습이 진행될수록 확률 질량이

이들 소수 궤적에 집중된다. 그 결과 동일한 문제에 대해 다양한 풀이 전략을 유지하기보다 하나의 성공 전략에 고착되는 전략 붕괴(strategy collapse)가 나타난다[2]. 그러나 음의 advantage를 갖는 실패 궤적이 항상 무의미한 것은 아니다. 일부 실패 경로는 부분적 오류만을 포함하며, 적절한 교정을 거치면 정답에 도달할 수 있는 잠재적 전략을 담고 있다. 그럼에도 표준 RLVR은 이러한 궤적을 다른 실패 궤적과 함께 일괄적으로 억제하므로, 보존할 가치가 있는 대안 전략을 잃고 탐색 범위가 좁아질 수 있다.

2.2 Textual Feedback and Self-Distillation Policy Optimization

LLM 에이전트는 응답 생성이 실패하더라도 단위 테스트 결과, 오류 메시지, 실행 로그와 같은 텍스트 피드백을 환경으로부터 받을 수 있다. 이러한 피드백은 실패한 추론 궤적을 단순히 폐기하는 대신, 어떤 부분을 교정해야 하는지에 대한 정보를 제공한다. 따라서 텍스트 피드백은 언어 모델이 무작위적인 탐색에 의존하지 않고, 비교적 제한된 탐색 공간 안에서 실패 경로를 수정할 수 있도록 하는 신호로 활용될 수 있다[3].

SDPO(Self-Distillation Policy Optimization)는 이러한 관찰을 바탕으로 실패 rollout에서도 학습 신호를 추출하는 자기 증류 기반 강화학습 방법이다. 질문 x 에 대해 모델이 응답 $\llbracket (\llbracket y \rrbracket) \rrbracket$ 를 생성하고 환경으로부터 피드백 f 를 받으면, SDPO는 동일한 모델에 피드백 f 를 추가 조건으로 제공하여 self-teacher 분포를 구성한다. 이때 self-teacher는 $\pi_{\theta}(\cdot | x, f, y_{\leq t})$ 로 표현되며, 학생 정책 $\pi_{\theta}(\cdot | x, y_{\leq t})$ 이 각 토큰 단계에서 어떤 토큰을 더 선호해야 하는지를 나타내는 기준으로 사용된다[3]. 학습 시 self-teacher 분포에는 그래디언트를 전달하지 않기 때문에, 이는 현재 모델이 피드백을 반영했을 때 형성하는 정지된 교사 분포로 해석할 수 있다.

SDPO의 목적함수는 각 토큰 단계에서 학생 분포 $\pi_{\theta}(\cdot | x, y_{\leq t})$ 를 stop-gradient가 적용된 self-teacher 분포 $\pi_{\theta}(\cdot | x, f, y_{\leq t})$ 에 가깝게 만드는 형태로 정의된다. 구체적으로 SDPO는 음의 reverse KL을 최대화하며, 이는 동치적으로 학생 분포와 self-teacher 분포 사이의 reverse KL을 최소화하는 것과 같다.

$$\begin{aligned} \max \mathbb{E}_{\tau \sim \pi_{\theta}} [r(\tau)] - \sum_t \mathbb{E}_{\tau \sim \pi_{\theta}} [r(\tau) \cdot \pi_{\theta}(\tau_t | x, y_{\leq t})] \\ = 1 \wedge \mathbb{E}_{\tau \sim \pi_{\theta}} [r(\tau) \cdot \pi_{\theta}(\tau_t | x, y_{\leq t})] \\ [KL(\pi_{\theta}(\cdot | x, y_{\leq t}) || \text{stopgrad}(\pi_{\theta}(\cdot | x, f, y_{\leq t})))] \end{aligned}$$

이 목적함수는 매 토큰 단계에서 학생 정책의 어휘 분포가 피드백을 반영한 self-teacher의 어휘 분포와 가까워지도록 유도한다. 이를 정책 그래디언트 형태로 전개하면 다음과 같이 나타낼 수 있다.

$$\nabla_{\theta} J = \sum_{t=1}^T \mathbb{E}_{\pi_{\theta}(\cdot | x, y_{<t})} [A((y_t)_t) \nabla_{\theta} \log(\pi_{\theta}((y_t)_t | x, y_{<t}))]$$

이때 각 토큰 후보, 즉 행동의 확률은 advantage에 비례하여 조정된다. SDPO에서 advantage는 self-teacher와 student가 해당 토큰에 부여하는 확률의 로그 비율로 정의된다.

$$A((y_t)_t) = \log \left(\frac{\pi_{\theta}((y_t)_t | x, f, y_{<t})}{\pi_{\theta}((y_t)_t | x, y_{<t})} \right)$$

따라서 advantage의 부호는 self-teacher와 student의 상대적 선호에 의해 결정된다. 피드백을 반영한 self-teacher가 student보다 특정 토큰에 더 높은 확률을 부여하면 해당 토큰의 advantage는 양수가 되고, 반대로 더 낮은 확률을 부여하면 음수가 된다. 여기서 학습 신호의 단위는 궤적(전체 시퀀스), 토큰(각 위치에서 실현된 단어), 로짓(각 위치에서 어휘의 각 후보에 대응하는 변수)의 계층으로 구분된다. 표준 RLVR이 궤적 전체에 단일 advantage를 부여하는 것과 달리, SDPO의 advantage는 각 위치의 로짓 단위마다 정의된다.

$$A((y_t)_t) = \begin{cases} > 0 & \text{if } \pi_{\theta}((y_t)_t | x, f, y_{<t}) > \pi_{\theta}((y_t)_t | x, y_{<t}) \\ = 0 & \text{if } \pi_{\theta}((y_t)_t | x, f, y_{<t}) = \pi_{\theta}((y_t)_t | x, y_{<t}) \\ < 0 & \text{if } \pi_{\theta}((y_t)_t | x, f, y_{<t}) < \pi_{\theta}((y_t)_t | x, y_{<t}) \end{cases}$$

이 구조는 실패한 rollout에 대해서도 로짓 단위의 학습 신호를 제공한다는 점에서 중요하다. 기존 RLVR이 실패한 궤적 전체의 확률을 낮추는 방향으로 작동하는 반면, SDPO는 실패 응답에 포함된 토큰들을 피드백을 반영한 self-teacher의 선호에 따라 세밀하게 재가중한다. 그 결과 실패한 rollout은 단순히 억제되어야 할 대상이 아니라, 적절한 피드백을 통해 교정 가능한 추론 경로로 활용될 수 있다.

2.3 KL Divergence Direction and Logit-level Learning Signals

SDPO는 reverse KL 기반의 학습 신호를 사용하지만, KL divergence의 방향은 로짓 단위 그래디언트의 성질에 직접적인 영향을 준다. Reverse KL을 정책 그래디언트 형태로 전개하면, 각 토큰 후보에 대한 학습 신호는 self-teacher와 student의 로그 확률 차이, 즉 로그 비율에 의해 결정된다. 따라서 해당 신호는 self-teacher가 student보다 더 선호하는 토큰에 대해서는 양의 신호가 주어지고, 덜 선호하는 토큰에 대해서는 음의 신호가 주어질 수 있다.

반면 forward KL을 동일한 정책 그래디언트 형태로 전개하면, 각 토큰 후보의 가중치는 self-teacher와 student의 확률 비율로 주어진다.

$$A^{\text{FKL}}((y_t)_t) = \frac{\pi_{\theta}((y_t)_t | x, f, y_{<t})}{\pi_{\theta}((y_t)_t | x, y_{<t})}$$

이 가중치는 비음수 값을 가지며, self-teacher가 높은 확률을 부여한 토큰일수록 더 큰 학습 신호를 받는다. 다만 이는 모든 토큰의 확률을 동일하게 증가시킨다는 의미가 아니라, self-teacher 분포가 선호하는 토큰을 상대적으로 더 강하게 모방하도록 만드는 중요도 가중치로 해석할 수 있다. 본 연구는 이러한 KL 방향의 차이가 성공 rollout과 실패 rollout에 서로 다른 귀납적 편향(inductive bias)을 제공할 수 있다고 보고, 이를 실험적으로 검토한다.

3. Method

본 연구의 방법론은 두 단계의 실험으로 구성된다. 첫째, SDPO가 실패 rollout을 학습에 활용함에도 불구하고 전략 다양성을 보존하는지 확인하기 위해 사전 실험을 수행한다. 이 실험에서는 base 모델, SDPO, 그리고 실패 rollout만으로 학습한 변형을 비교하여 SDPO에서 전략 붕괴가 발생하는지와 실패 rollout이 전략 다양성 보존에 기여할 수 있는지를 분석한다. 둘째, 사전 실험의 관찰을 바탕으로 rollout의 성공 여부에 따라 서로 다른 KL 목적함수를 적용하는 결과 기반 KL 라우팅 방법을 설계하고 평가한다.

3.1 Preliminary Experiment Methodology

사전 실험의 목적은 SDPO가 정답 전략 다양성을 보존하는지, 그리고 실패 rollout만을 활용한 학습이 전략 다양성에 어떤 영향을 미치는지 확인하는 것이다. 이를 위해 본 연구는 동일한 기반 모델

에서 세 가지 설정을 비교한다.

첫 번째는 추가 학습을 수행하지 않은 base 모델이다. 두 번째는 텍스트 피드백을 활용하는 SDPO 모델이다. SDPO는 성공 및 실패 rollout으로부터 self-teacher 분포를 구성하고, 이를 student 정책이 모방하도록 학습한다. 세 번째는 실패 rollout만을 사용하여 학습한 Failure-only 모델이다. 이는 실패한 응답과 그에 대한 텍스트 피드백만을 학습 신호로 사용함으로써, 실패 rollout이 전략 다양성 보존에 기여할 수 있는지를 확인하기 위한 비교군이다.

모든 실험은 Qwen3-8B[4]를 기반 모델로 사용하며, 코드 생성 벤치마크인 LiveCodeBench v6(LCB v6)[5]에서 수행한다. 각 문제에 대해 여러 개의 응답을 샘플링하고, 단위 테스트를 통과한 응답을 정답 솔루션으로 간주한다. 이후 정답 솔루션들을 GP T-5.4-mini judge를 사용해 풀이 전략 단위로 분류한다. 여기서 전략 다양성은 동일한 문제를 해결하는 정답 솔루션들이 서로 다른 풀이 방식으로 분산되어 있는 정도를 의미한다.

평가 지표로는 Pass@16, 문제당 평균 전략 수(Avg. Strategies), 유효 전략 수(Effective Strategies), 단일 전략 비율(Single-Strategy)을 사용한다. Pass@16은 제한된 샘플 수 안에서 정답에 도달하는 샘플링 효율을 측정한다. Avg. Strategies는 문제별로 관찰된 서로 다른 정답 전략의 평균 개수를 나타내며, Effective Strategies는 전략 분포의 집중도를 반영한 유효 전략 수를 나타낸다. Single-Strategy는 정답 솔루션이 하나의 전략에만 집중된 문제의 비율을 의미한다. 사전 실험의 결과는 4.1에서 제시한다.

Model	Pass@16 (%)	Avg. Strategies	Effective Strategies	Single-Strategy (%)
Base (Qwen3-8B)	42.7	1.66	1.44	53.6
SDPO	49.6	1.15	1.10	90.8
Failure-only	43.5	1.86	1.64	45.6

표1. 사전 실험에서의 정답 솔루션 전략 다양성 비교 (Judge만 GPT-5.4-mini) 기반 KL 방향 설계는 초기 Base, SDPO, Failure-only 모델을 비교하였으며, judge는 GPT-5.4-mini를 사용하였다. Pass@16, Avg. Strategies, Effective Strategies는 높을수록 좋고, Single-Strategy는 5점 이하가 바람직하며, 클수록 더 나은 구성 글씨는 최고 성능, 밑줄은 차순위 성능을 나타낸다. 조와 KL 계측을 통해 다시 검토한다.

3.2 Main Experiment Methodology

사전 실험은 성공 rollout과 실패 rollout이 서로 다른 학습적 역할을 가질 수 있음을 확인하기 위한 것이다. 성공 rollout은 정답에 도달한 경로이므로 샘플링 효율을 높이는 데 기여할 수 있지만, 과도하게 강화될 경우 정답 전략이 소수의 경로로 집중될 수 있다. 반면 실패 rollout은 직접적인 정답 신호를 제공하지는 않지만, 텍스트 피드백을 통해 교정 가능한 대안적 추론 경로를 포함할 수

있다. 본 연구는 이러한 차이에 기반하여 rollout의 성공 여부에 따라 서로 다른 KL 목적함수를 적용하는 결과 기반 KL 라우팅 방법을 제안하고 평가한다. 이하에서는 이 제안 방법을 DSPO(Divergence-routed Self-Distillation Policy Optimization)로 지칭한다. DSPO는 기존 SDPO의 self-teacher 기반 자기 증류 구조를 유지하되, rollout의 성공 여부에 따라 적용하는 KL divergence 방향을 달리하는 방법이다.

제안 방법은 rollout의 결과에 따라 손실을 분기한다. 성공한 rollout에 대해서는 forward KL을 적용한다. 성공 rollout은 이미 정답에 도달한 궤적이므로, self-teacher가 부여한 확률 분포를 비율수 중요도 가중치로 모방함으로써 정답 경로의 샘플링 효율을 유지하는 것을 목표로 한다. 반면 실패한 rollout에 대해서는 reverse KL을 적용한다. 실패 rollout은 정답에 도달하지 못했지만, 텍스트 피드백을 통해 교정 가능한 추론 경로를 포함할 수 있다. 따라서 self-teacher와 student의 로그 확률 차이에 기반한 양수 및 음수 신호를 사용하여, 피드백을 반영한 self-teacher가 선호하는 토큰은 강화하고 덜 선호하는 토큰은 억제하도록 한다.

두 분기의 로짓 단위 학습 신호는 각각 다음과 같이 정의된다.

$$A^{\wedge} [FKL] = \frac{[["success"] (([y])_t)]}{[[\pi_{\theta} (([y])_t | x, f, y_{<t})]]} / [[\pi_{\theta} (([y])_t | x, y_{<t})]]$$

$$A^{\wedge} [RKL] = \frac{[["failure"] (([y])_t)]}{\log [[\pi_{\theta} (([y])_t | x, f, y_{<t})]]} / [[\pi_{\theta} (([y])_t | x, y_{<t})]]$$

각각의 식은 성공 rollout에 적용되는 forward KL 기반의 비율수 중요도 가중치, 실패 rollout에 적용되는 reverse KL 기반의 로그 비율 advantage이

3.3 Final Objective

최종 학습 목적함수는 성공 rollout에 대한 forward KL 손실과 실패 rollout에 대한 reverse KL 손실을 결합하여 구성한다. 본 연구에서는 두 분기의 손실을 동일한 가중치로 결합하며, 최종 손실은 다음과 같다.

$$L = \frac{L_{\text{success}}}{L_{\text{failure}}} \cdot L_{\text{KL}}^{\text{success}} \cdot L_{\text{KL}}^{\text{failure}}$$

이 목적함수는 성공한 정답 경로의 샘플링 효율을 유지하면서도, 실패 rollout에 포함된 교정 가능한 추론 신호를 활용하여 대안적 전략을 보존하는 것을 목표로 한다. 메인 실험에서는 base 모델, SDPO, 그리고 결과 기반 KL 라우팅을 적용한 모델을 비교하며, 성능과 전략 다양성, pass@k 곡선을 통한 문제 커버리지, 분기별 손실 크기를 함께 분석한다. 해당 결과는 4.2에서 보고한다.

4. Results

4.1 Preliminary Experiment Results

먼저 SDPO가 전략 다양성을 보존하는지 확인하기 위해 base 모델, SDPO, 그리고 실패 rollout만으로 학습한 변형(Failure-only)을 비교하였다. 표 1은 각 모델의 Pass@16과 정답 전략 다양성 지표를 나타낸다.

SDPO는 Pass@16 기준으로 49.6%를 기록하여 base 모델의 42.7%보다 높은 샘플링 효율을 보였다. 그러나 전략 다양성 측면에서는 뚜렷한 감소가 관찰되었다. SDPO의 평균 전략 수는 1.15, 유효 전략 수는 1.10으로, base 모델의 1.66 및 1.44보다 낮았다. 또한 단일 전략 비율은 base 모델의 53.6%에서 SDPO의 90.8%로 크게 증가하였다. 이는 SDPO가 정답을 더 자주 샘플링하도록 만들지만, 정답에 도달하는 전략은 소수의 경로로 집중시킬 수 있음을 보여준다.

반면 Failure-only 모델은 Pass@16이 43.5%로 SDPO보다 낮았지만, 전략 다양성에서는 가장 높은 값을 보였다. 평균 전략 수는 1.86, 유효 전략 수는 1.64로 base 모델과 SDPO를 모두 상회하였고, 단일 전략 비율은 45.6%로 가장 낮았다. 이는 실패 rollout이 단순히 억제되어야 할 대상이 아니라, 다양한 정답 전략을 보존하는 데 기여할 수 있는 학습 신호일 가능성을 보여준다.

Model	Pass@16 (%)	Avg. Strategies	Effective Strategies	Single Strategy (%)
Base (Qwen3-8B)	42.7	2.05	1.70	41.1
SDPO	49.6	1.03	1.02	90.8
DSPO (Ours)	45.0	1.63	1.43	61.0

표2. 메인 실험에서의 정답 솔루션 전략 다양성 비교 (Judge: GPT-5.4-mini)
 Base, SDPO, 그리고 결과 기반 KL 라우팅을 적용한 제안 방법(Ours)을 비교하였다. Pass@16, Avg. Strategies, Effective Strategies, Single Strategy는 낮을수록 좋다. 굵은 붉은색 글씨는 최고 성능, 회색은 개선되었으나 SDPO만큼 강한 성능 향상에 도달하지 못했음을 의미한다. 전략 다양성 측면

그림1. Qwen3-8B의 LiveCodeBench v6 pass@k 곡선

k는 문제별 샘플 수를 의미하며, pass@k는 k개의 샘플 중 하나 이상이 정답인 경우를 의미한다. 그림의 DSPO는 결과 기반 KL 라우팅을 적용한 본 연구의 제안 방법이다.

이 결과는 SDPO가 샘플링 효율을 높이는 동시에 전략 다양성을 감소시킬 수 있음을 보여준다. 또한 실패 rollout만을 활용한 학습이 base 모델보다 높은 전략 다양성을 보였다는 점에서, 실패 rollout이 대안적 추론 전략을 보존하는 데 중요한 역할을 할 수 있음을 시사한다. 이러한 관찰을 바탕으로 본 연구는 성공 rollout과 실패 rollout을 서로 다른 KL 목적함수로 처리하는 결과 기반 라우팅을 평가하였다.

4.2 Main Experiment Results

4.2.1 Strategy Diversity

표 2는 결과 기반 KL 라우팅을 적용한 제안 방법(Ours)을 base 모델과 SDPO와 비교한 결과이다. 제안 방법은 Pass@16 45.0%, 평균 전략 수 1.63, 유효 전략 수 1.43, 단일 전략 비율 61.0%를 기록하였다. 이는 성능과 전략 다양성 모두에서 base 모델과 SDPO 사이의 중간 수준에 해당한다. GPT-5.4-mini 방법의 Pass@16은 base 모델 42.7%, SDPO 49.6%보다 4.9% 낮았다. 이는 실패 rollout이 높은 샘플링 효율을 제공하면서도, 높은 성능 향상에 도달하지 못했음을 의미한다. 전략 다양성 측면

에서도 제안 방법은 SDPO보다 높은 다양성을 유지하였다. SDPO는 평균 전략 수 1.03, 유효 전략 수 1.02, 단일 전략 비율 96.9%로 대부분의 정답이 단일 전략에 집중된 반면, 제안 방법은 평균 전략 수 1.63, 유효 전략 수 1.43, 단일 전략 비율 61.0%를 보였다.

Branch	Distribution	p_1 ["top" - 1]	H (nats)	p_1 ["top" - 1]	H (nats)
Success	Student	0.884 (± 0.187)	0.316 (± 0.479)	0.527	0.527
	Self-teacher	0.984 (± 0.063)	0.016 (± 0.012)	0.527	0.527
Fail	Student	0.834 (± 0.219)	0.470 (± 0.591)	0.470	0.470
	Self-teacher	0.834 (± 0.219)	0.470 (± 0.591)	0.470	0.470

표3. 성공 및 실패 분기에서의 student와 self-teacher p_1 ["top" - 1]은 top-1 토큰의 평균 확률을, H 는 토큰 분포의 엔트로피를 나타낸다. t와 self-teacher의 top-1 토큰이 서로 다른 비율을 나타낸다.

그러나 제안 방법은 base 모델 수준의 전략 다양성에는 도달하지 못했다. Base 모델은 평균 전략 수 2.05, 유효 전략 수 1.70, 단일 전략 비율 41.1%를 기록하였다. 따라서 결과 기반 KL 라우팅은 SDPO의 극단적인 전략 붕괴를 완화하였지만, base 모델이 가진 전략 다양성을 완전히 보존하지는 못하였다.

를 측정하였다. 그림 1은 base 모델, SDPO, 제안 방법의 pass@k 곡선을 나타낸다.

제안 방법은 k=1에서 pass@k 0.324를 기록하여 base 모델의 0.268보다 높고 SDPO의 0.473보다 낮은 지점에서 출발하였다. 이는 제안 방법이 base 모델보다 높은 초기 샘플링 효율을 보이지만, SDPO의 효율에는 미치지 못함을 보여준다. 이후 k가 증가함에 따라 제안 방법의 pass@k는 SDPO와 점차 가까워졌고, k=1792에서는 0.527로 SDPO와 동일한 값에 도달하였다. 따라서 제안 방법은 큰 샘플 수에서는 SDPO에 필적하는 성능을 보였다.

그러나 문제 커버리지 측면에서는 여전히 한계가 관찰되었다. Base 모델은 k=1792에서 pass@k 0.527를 기록하여 SDPO와 제안 방법의 0.527보다 높은 값을 유지하였다. 이는 학습된 두 모델이 제안된 샘플 수에서는 더 높은 샘플링 효율을 보일 수 있지만, 매우 큰 샘플 수에서 도달 가능한 문제의 범위는 base 모델보다 좁아질 수 있음을 의미한다. 결과적으로 제안 방법은 SDPO의 극단적인 전략 붕괴를 완화하고 큰 k에서 SDPO와 유사한 pass@k를 달성하였으나, base 모델의 문제 커버리지를 확장하는 데에는 실패하였다.

5. Discussion

4장의 결과는 결과 기반 KL 라우팅이 SDPO의 극단적인 전략 붕괴를 완화할 수는 있지만, base 모델 수준의 전략 다양성을 완전히 보존하거나 문제 커버리지를 확장하는 데에는 충분하지 않았음을 보여준다. 본 절에서는 이러한 한계의 원인을 분석한다. 먼저 동일 가중치로 결합한 두 손실이 실제로는 균형 잡힌 학습 신호를 만들지 못했음을 보인다. 이어서 성공 rollout과 실패 rollout에 적합한 KL 방향이 초기 설계 가정과 다를 수 있음을 분석한다. 마지막으로 분기별 KL 크기 계측과 정성 사례를 통해 이러한 해석을 뒷받침한다.

5.1 Loss Imbalance between Success and Failure Branches

그림2. 학습 중 성공 분기와 실패 분기의 증류 손실 변화

성공 rollout에 적용된 forward KL 손실과 실패 rollout에 적용된 reverse KL 손실의 변화를 비교한다. 파란색은 성공 rollout의 forward KL 손실을, 빨간색은 실패 rollout의 reverse KL 손실을 나타낸다.

4.2.2 Pass@k and Problem Coverage

전략 다양성뿐만 아니라 문제 커버리지의 변화를 확인하기 위해 샘플 수 k를 증가시키며 pass@k

제안 방법은 성공 rollout의 forward KL 손실과 실패 rollout의 reverse KL 손실을 동일한 가중치로 결합하였다. 그러나 학습 중 두 분기의 손실 크기를 계측한 결과, 실제 학습 신호는 성공 분기에 크게 치우쳐 있었다. 그림 2에서 성공 분기의 forward KL 손실은 약 0.2 수준으로 유지된 반면, 실패 분기의 reverse KL 손실은 약 0.009 수준에 머물렀다. 이는 성공 분기의 손실이 실패 분기보다 약

21배 크다는 것을 의미한다. 따라서 두 손실을 동일한 계수로 결합하더라도, 실제 최적화 과정에서는 성공 분기의 신호가 전체 학습을 지배하게 된다.

이러한 불균형은 self-teacher 분포의 형태와 관련된다. 표 3에서 볼 수 있듯이, 성공 rollout을 조건으로 받은 self-teacher는 매우 첨예한(peaked) 분포를 형성한다. 성공 분기에서 self-teacher의 top-1 확률은 평균 0.984이고 엔트로피는 0.050 nats로, student의 top-1 확률 0.884 및 엔트로피 0.316 nats보다 훨씬 결정적이다. 이는 성공한 정답 경로를 조건으로 받은 self-teacher가 특정 토큰에 매우 높은 확률을 부여한다는 것을 의미한다.

결과적으로 동일 가중치 결합은 의도한 것과 달리 성공 rollout 중심의 학습을 유도하였다. 본 연구의 목표는 성공 rollout을 통해 샘플링 효율을 유지하면서 실패 rollout의 교정 신호를 활용하는 것이었지만, 실패 분기의 손실 크기가 지나치게 작았기 때문에 대안적 추론 전략을 충분히 강화하지 못한 것으로 해석할 수 있다. 이는 단순히 손실 항을 더하는 것만으로는 성공과 실패 rollout의 학습 기여도를 균형 있게 조절하기 어렵다는 점을 보여준다.

5.2 KL Direction and Exploration

두 번째 원인은 KL 방향과 rollout 결과 사이의 적합성에 있다. 본 연구의 초기 설계는 성공 rollout에는 forward KL을, 실패 rollout에는 reverse KL을 적용하는 것이었다. 성공한 rollout은 비음수 가중치를 통해 보상하고, 실패한 rollout은 self-teacher의 선호에 따라 양수 및 음수 신호로 교정한다는 가정이었다. 그러나 그래디언트 구조를 살펴보면, 실패 분기에서 reverse KL은 새로운 행동을 탐색하는 데 제한적일 수 있다.

Reverse KL의 그래디언트를 어휘 전체에 대한 합으로 전개하면 다음과 같다.

$$\begin{aligned} \nabla_{\theta} J &= \sum_{t=1}^{|y|} E_{\pi_{\theta}} \left[\left(\frac{\log \pi_{\theta}(\hat{y}_t | x, f, y_{<t})}{\pi_{\theta}(\hat{y}_t | x, y_{<t})} \right) \cdot \nabla_{\theta} \log \pi_{\theta}(\hat{y}_t | x, y_{<t}) \right] \\ &= \sum_{t=1}^{|y|} \sum_{\hat{y}_t \in \text{cal } V} \pi_{\theta}(\hat{y}_t | x, y_{<t}) \log \left(\frac{\pi_{\theta}(\hat{y}_t | x, f, y_{<t})}{\pi_{\theta}(\hat{y}_t | x, y_{<t})} \right) \nabla_{\theta} \log \pi_{\theta}(\hat{y}_t | x, y_{<t}) \end{aligned}$$

$$\times \nabla_{\theta} \log \pi_{\theta}(\hat{y}_t | x, y_{<t})$$

위 reverse KL 그래디언트에서 각 행동의 학습 신호에는 student가 해당 행동에 부여한 확률 $\pi_{\theta}(\cdot | x, y_{<t})$ 이 곱해진다. 이 항은 advantage의 효과를 약화시키며, student가 낮은 확률을 부여한 행동은 self-teacher가 선호하더라도 빠르게 확률이 증가하기 어렵다. 특히 top-k 근사를 사용하는 경우 이 문제는 더 커질 수 있다. self-teacher가 선호하는 행동이라도 student의 top-k 후보 안에 포함되지 않으면 해당 행동은 학습 신호에서 제외될 수 있기 때문이다.

이 관점에서 보면 실패 rollout에 reverse KL을 적용하는 것은 탐색 측면에서 제한적이다. 모델의 실패는 정답으로 이어질 수 있는 고품질 행동이 현재 student 분포의 낮은 확률 영역에 존재할 가능성을 시사한다. 그러나 reverse KL은 student가 이미 일정 확률을 부여한 행동을 중심으로 분포를 정제하는 데 강점을 가지므로, 낮은 확률 아래 숨어 있는 새로운 행동을 끌어올리는 데에는 충분하지 않을 수 있다.

반면 forward KL은 학습 신호가 student 자신의 확률로 직접 가중되지 않는다는 점에서 실패 분기의 탐색에 더 적합할 수 있다.

$$\begin{aligned} \nabla_{\theta} J &= \sum_{t=1}^{|y|} E_{\pi_{\theta}} \left[\left(\frac{\log \pi_{\theta}(\hat{y}_t | x, f, y_{<t})}{\pi_{\theta}(\hat{y}_t | x, y_{<t})} \right) \cdot \nabla_{\theta} \log \pi_{\theta}(\hat{y}_t | x, y_{<t}) \right] \\ &= \sum_{t=1}^{|y|} \sum_{\hat{y}_t \in \text{cal } V} \pi_{\theta}(\hat{y}_t | x, f, y_{<t}) \nabla_{\theta} \log \pi_{\theta}(\hat{y}_t | x, y_{<t}) \end{aligned}$$

위 forward KL 그래디언트에서는 student 확률 항이 중요도 비율의 분모와 약분되며, 최종적으로 self-teacher가 부여한 확률 $\pi_{\theta}(\cdot | x, f, y_{<t})$ 이 직접적인 가중치로 남는다. 따라서 self-teacher가 높은 확률을 부여한 행동, 즉 teacher의 top-k 후보에 포함된 행동은 student가 기존에 낮은 확률을 부여했더라도 상대적으로 강한 학습 신호를 받을 수 있다. 이는 실패한 응답에 대한 텍스트 피드백이 기존 student 분포의 저확률 영역에 있는 교정 방향을 제시할 때 중요한 성질이다.




그림 3. 성공 분기에서의 forward KL과 reverse KL 크기 비교

성공 rollout을 조건으로 구성된 self-teacher 분포와 student 분포 사이의 KL divergence를 학습 단계별로 나타낸다. 빨간색은 teacher top-k 기준의 forward KL을, 파란색은 student top-k 기준의 reverse KL을 나타낸다. x축은 training step, y축은 sequence-level 평균 KL divergence를 나타낸다.




그림 4. 실패 분기에서의 forward KL과 reverse KL 크기 비교

실패 rollout과 텍스트 피드백을 조건으로 구성된 self-teacher 분포와 student 분포 사이의 KL divergence를 학습 단계별로 나타낸다. 빨간색은 teacher top-k 기준의 forward KL을, 파란색은 student top-k 기준의 reverse KL을 나타낸다. x축은 training step, y축은 sequence-level 평균 KL divergence를 나타낸다.

그림 5. 성공 rollout의 특정 토큰 위치에서의 student와 self-teacher 분포 비교

x축은 student의 확률 기준으로 정렬된 top-20 토큰 후보를, y축은 각 토큰의 확률을 나타낸다. 파란색은 student 분포를, 주황색은 self-teacher 분포를 나타낸다.

반대로 성공 rollout에는 reverse KL이 더 적합할 수 있다. 성공했다는 것은 모델이 이미 해당 정답 경로를 샘플링할 수 있을 만큼 충분한 확률을 부여하고 있음을 의미한다. 이 경우 새로운 행동을 넓게 탐색하기보다는, 이미 성공한 경로 주변의 분포를 정제하는 mode-seeking 성질이 더 유리할 수 있다. 따라서 본 연구의 결과는 초거 설계와 달리

실패 rollout에는 forward KL이, 성공 rollout에는 reverse KL이 더 적합할 수 있음을 시사한다. 이는 초거의 rollout의 성공을 위한 self-teacher의 forward KL을 과대평가한 student to teacher sequence-level 평균 KL divergence를 함께 고려해야 함을 의미한다.




그림 6. 실패 rollout의 특정 토큰 위치에서의 student와 self-teacher 분포 비교

x축은 self-teacher의 확률 기준으로 정렬된 top-20 토큰 후보를, y축은 각 토큰의 확률을 나타낸다. 파란색은 student 분포를, 주황색은 self-teacher 분포를 나타낸다.

5.3 Branch-wise KL Magnitudes

이러한 해석을 확인하기 위해 학습 중 각 분기에서 forward KL과 reverse KL의 크기를 함께 계속하였다. 일반적으로 forward KL은 mass-covering 성질을, reverse KL은 mode-seeking 성질을 갖는 것으로 알려져 있다[6]. 여기서 mass-covering은 teacher가 높은 확률을 부여한 다양한 후보를 포괄하려는 경향을 의미하고, mode-seeking은 이미 높은 확률이 할당된 주요 모드에 집중하는 경향을 의미한다.

그림 3은 성공 분기에서의 forward KL과 reverse KL 계측 결과를 보여준다. 성공 분기에서는 reverse KL이 forward KL보다 일관되게 크게 나타났다.

이는 성공 rollout에서 student와 self-teacher의 support가 비교적 유사하며, reverse KL이 이미 상당한 확률이 할당된 행동들을 정제하는 강한 신호를 만든다는 해석과 일치한다. 따라서 성공 분기에서는 forward KL보다 reverse KL이 더 의미 있는 정제 신호를 제공할 가능성이 있다.

반대로 그림 4는 실패 분기에서의 KL 계측 결과를 보여준다. 실패 분기에서는 forward KL이 reverse KL보다 일관되게 크게 나타났다. 이는 self-teacher가 student의 낮은 확률 영역에 있는 행동을 선호하는 상황, 즉 mass-covering이 필요한 상황이 실패 분기에서 자주 발생함을 의미한다. 이러한 결과는 실패 rollout에서 reverse KL만을 사용하는 것이 탐색 신호를 충분히 반영하지 못했을 가능성을 뒷받침한다. 다만 실패 분기에서도 모든 경우에 forward KL만이 유리하다고 단정할 수는 없으며, 일부 상황에서는 reverse KL이 여전히 유용할 수 있다. 따라서 KL 방향은 성공/실패라는 이진 결과에 고정되기보다, 분포 간 support의 겹침 정도와 손실 크기에 따라 동적으로 선택될 필요가 있다.

5.4 Qualitative Analysis

분기별 KL 방향의 차이는 정성 사례에서도 관찰된다. 그림 5는 성공 rollout에서의 사례를 보여준다. 배열 nums에 대한 연산 횟수를 구하는 문제에서 student의 top-1 토큰은 min, top-2 토큰은 nums였고, 모델은 nums를 샘플링하여 정답에 도달하였다. 정답 솔루션을 조건으로 받은 self-teacher 역시 해당 위치에서 nums를 선호하였다. 이 위치에서 reverse KL은 13.85로, forward KL의 1.50보다 훨씬 크게 나타났다. 이는 student가 이미 상당한 확률을 부여한 행동을 self-teacher가 다시 강화하는 상황에서는 reverse KL이 강한 정제 신호를 만든다는 것을 보여준다.

그림 6은 실패 rollout에서의 사례이다. 주어진 문자열을 접두사로 갖는 가장 짧은 회문을 찾는 문제에서 student는 오답을 생성했고, KSHJFGF 입력에 대한 테스트케이스 피드백을 받았다. 피드백을 반영한 self-teacher는 예시 구문의 K 토큰에 높은 확률을 부여했지만, student의 해당 토큰 확률은 거의 0에 가까웠다. 이 위치에서 forward KL은 6.22로, reverse KL의 0.48보다 훨씬 크게 나타났다. 이는 self-teacher가 student의 저확률 행동을 선호하는 전형적인 mass-covering 상황이며, 실패 분기의 탐색 신호가 forward KL 쪽에 더 강하게 실려 있음을 보여준다.

종합하면, 결과 기반 라우팅은 성공 rollout과 실패 rollout을 동일한 손실로 처리해서는 안 된다는 점을 보여주지만, 각 분기를 하나의 고정된 KL 방향에 대응시키는 것만으로는 충분하지 않았다. 성공 rollout은 이미 도달 가능한 정답 경로를 정

제하는 문제에 가깝고, 실패 rollout은 피드백을 통해 저확률 영역의 교정 가능한 행동을 끌어올리는 문제에 가깝다. 따라서 향후에는 rollout의 성공 여부뿐만 아니라 self-teacher와 student 분포의 차이, top-k support의 겹침 정도, 분기별 손실 크기를 함께 고려하는 동적 라우팅이 필요하다.

6. Conclusion

본 연구는 텍스트 피드백 기반 자기 증류 강화학습 방법인 SDPO(Self-Distillation Policy Optimization)에서 전략 붕괴(strategy collapse)가 발생하는지 분석하고, 이를 완화하기 위한 결과 기반 KL 라우팅 방법을 제안하였다. 먼저 LiveCodeBench v6 코드 생성 과제에서 SDPO 학습 이후 정답 전략 다양성이 크게 감소함을 확인하였다. 반면 실패 rollout만을 활용한 학습 변형은 base 모델보다 높은 전략 다양성을 보여, 실패 rollout이 단순히 억제되어야 할 대상이 아니라 대안적 추론 전략을 보존하는 학습 신호가 될 수 있음을 보였다.

이 관찰을 바탕으로 본 연구는 성공 rollout에는 forward KL을, 실패 rollout에는 reverse KL을 적용하는 결과 기반 라우팅 방법을 평가하였다. 제안 방법은 SDPO의 극단적인 단일 전략 수렴을 완화하고, 성능과 다양성 측면에서 base 모델과 SDPO 사이의 중간적인 결과를 보였다. 그러나 큰 샘플 수에서 base 모델의 문제 커버리지를 확장하는 데에는 실패하였다.

추가 분석에서는 이러한 한계의 원인을 두 가지 관점에서 확인하였다. 첫째, 성공 분기의 forward KL 손실이 실패 분기의 reverse KL 손실보다 훨씬 크게 나타나, 동일 가중치 결합에도 불구하고 실제 학습 신호가 성공 rollout 중심으로 치우쳤다. 둘째, KL 방향과 rollout 결과 사이의 적합성이 초기 가정과 다를 수 있음을 확인하였다. 특히 실패 rollout에서는 self-teacher가 student의 저확률 행동을 선호하는 경우가 관찰되었으며, 이 경우 reverse KL보다 forward KL이 더 강한 탐색 신호를 제공할 수 있었다. 반대로 성공 rollout에서는 이미 확률이 할당된 정답 경로를 정제하는 reverse KL이 더 적합할 가능성이 나타났다.

본 연구에는 몇 가지 한계가 있다. 첫째, 실패 rollout이 전략 다양성 보존에 기여할 수 있음은 확인하였지만, 이를 성공 rollout 기반 학습과 균형 있게 결합하는 방법은 충분히 검증하지 못했다. 이러한 결합 문제는 서로 충돌하는 그래디언트를 조정하는 PCGrad[8]와 같은 그래디언트 조작(gradient manipulation) 기법을 통해 완화될 수 있을 것으로 기대된다. 둘째, 성공 여부에 따라 KL 방향을 고정적으로 전환하는 방식은 최적화 과정에서 불연속성을 만들 수 있으며, 실제 분기별 분석은 성공

rollout에는 reverse KL, 실패 rollout에는 forward KL이 더 적합할 가능성을 보였다. 예를 들어 forward KL로 특정 행동의 확률을 끌어올려 결국 성공에 도달하면, 해당 rollout은 다시 reverse KL 분기로 급격히 전환된다. 이러한 불연속성은 앞서 언급한 성공, 실패 분기의 균형 문제와 다시 연결된다. 다만 이 뒤바뀐 방향을 직접 학습하거나 평가하지는 못했으며, 이는 향후 과제로 남긴다. 마지막으로, 본 연구는 전략 다양성이 큰 k에서의 pass@k 유지에 중요하다고 주장하였지만, 제안 방법이 base 모델의 문제 커버리지를 넘어서는 결과를 실증적으로 보이지는 못했다. 다만 탐색적 추론을 명시적으로 학습하는 Poly-EPO[2]의 최근 결과는, 전략 다양성이 큰 k에서의 pass@k 유지에 기여한다는 본 연구의 주장을 뒷받침한다. 향후에는 분기별 손실 크기, top-k support 겹침 정도, self-teacher와 student 간 불일치 정도를 함께 고려하는 동적 라우팅 및 가중치 조정 방법을 검토할 필요가 있다.

종합하면, 본 연구는 SDPO에서 실패 rollout이 전략 다양성 보존에 중요한 역할을 할 수 있음을 보였으며, 성공과 실패 rollout을 구분한 손실 설계의 필요성을 제기하였다. 비록 제안한 고정형 KL 라우팅은 문제 커버리지 확장에는 실패했지만, 그 실패 원인을 분석함으로써 향후 자기 증류 기반 강화학습에서 탐색과 정제를 균형 있게 결합하기 위한 방향을 제시하였다.

7. Reference

- [1] Yue, Y., Chen, Z., Lu, R., Zhao, A., Wang, Z., Yue, Y., Song, S., & Huang, G. (2025). Does Reinforcement Learning Really Incentivize Reasoning Capacity in LLMs Beyond the Base Model? arXiv preprint arXiv:2504.13837.
- [2] Orney, I. H., Hamid, J. I., Ramanujam, S. S., Wu, S., Hu, H., Goodman, N., Sadigh, D., & Finn, C. (2026). Poly-EPO: Training Exploratory Reasoning Models. arXiv preprint arXiv:2604.17654.
- [3] Hübötter, J., Lübeck, F., Behric, L., Baumann, A., Bagatella, M., Marta, D., Hakimi, I., Shenfeld, I., Kleine Buening, T., Guestrin, C., & Krause, A. (2026). Reinforcement Learning via Self-Distillation. International Conference on Machine Learning (ICML), 2026. arXiv preprint arXiv:2601.20802.
- [4] Yang, A., Li, A., Yang, B., Zhang, B., Hui, B., Zheng, B., Yu, B., Gao, C., Huang, C., Lv, C., Zheng, C., Liu, D., Zhou, F., Huang, F., Hu, F., Ge, H., Wei, H., Lin, H., Tang,

- J., Yang, J., et al. (2025). Qwen3 Technical Report. arXiv preprint arXiv:2505.09388.
- [5] Jain, N., Han, K., Gu, A., Li, W.-D., Yan, F., Zhang, T., Wang, S., Solar-Lezama, A., Sen, K., & Stoica, I. (2024). LiveCodeBench: Holistic and Contamination Free Evaluation of Large Language Models for Code. arXiv preprint arXiv:2403.07974.
- [6] Manisha, P., & Gujar, S. (2018). Generative Adversarial Networks (GANs): What It Can Generate and What It Cannot? arXiv preprint arXiv:1804.00140.
- [7] Shao, Z., Wang, P., Zhu, Q., Xu, R., Song, J., Bi, X., Zhang, H., Zhang, M., Li, Y.K., Wu, Y., & Guo, D. (2024). DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models. arXiv preprint arXiv:2402.03300.
- [8] Yu, T., Kumar, S., Gupta, A., Levine, S., Hausman, K., & Finn, C. (2020). Gradient Surgery for Multi-Task Learning. Advances in Neural Information Processing Systems (NeurIPS), 33, 5824–5836.